

Estimación de la duración de procesos en una asesoría

Entrega 4 — Diseño del análisis y estrategia de modelado

Índice

Respuesta al feedback de las entregas 2 y 3	1
1. Problema que se busca resolver	3
1.1 Qué ocurre hoy y por qué es un problema	3
1.2 Quién usa el resultado y para qué decisión	3
1.3 Qué resultado se considera útil	3
1.4 Alcance: una sola línea, un solo pipeline	3
2. Análisis de datos planteado y utilidad esperada	4
2.1 Preguntas que se responden con los datos	4
2.2 Cómo alimenta el modelado y el MVP	4
3. Tipo de modelos que se van a plantear	5
4. Datos de entrada del análisis y los modelos	5
5. Datos de salida y forma de consumo	6
6. Estrategia para diseñar y seleccionar el modelo	7
7. Estrategia de validación y evaluación	8
8. Riesgos y alternativas	9
9. Limitaciones declaradas	10
10. Trabajo futuro y estado de la entrega	10
10.1 Qué desbloquearía cada línea	10
10.2 Seguridad y reproducibilidad	11
10.3 Lo que queda pendiente	11
10.4 Trazabilidad de las cifras	11

Respuesta al feedback de las entregas 2 y 3

Observación del tutor	Qué se ha cambiado	Dónde verlo
Abarcaba predicción, anomalías y segmentación a la vez	Una sola línea: estimación de duración. La anomalía es el residuo del mismo modelo, no un modelo aparte	§ 1 Problema; § 8 Riesgos

Observación del tutor	Qué se ha cambiado	Dónde verlo
19 meses no permiten predecir 2027	Se abandona la extrapolación temporal. Regresión transversal: una negociación ejecutada es una observación	§ 1 Problema; § 6 Estrategia de selección
Muy pocos meses por cliente	La unidad pasa de cliente $\times$ mes a negociación. 13.013 observaciones sobre 1.036 clientes	§ 4 Datos de entrada
Afirmar acceso garantizado y calidad excelente sin explorar	Fase de calidad ejecutada antes de escribir la memoria, con cifras. El 21,74 % de las negociaciones cerradas del pipeline tiene 0 minutos imputados y el 11,71 % de las horas no cuelga de ninguna negociación	§ 2 Análisis de datos
No demostraba mejorar un análisis sencillo	Cuatro baselines calculados antes que el modelo. B1 (mediana por proceso) fijado como referencia: MAE 16,37 min. El modelo mejora un 5,31 %, por debajo del 10 % que se había fijado como umbral, y así se reporta	§ 3 Tipos de modelo; § 7 Validación
Sin plan contra el leakage temporal	Split temporal por campaña (cierres de 2025 frente a cierres de 2026) y GroupKFold(4) por cliente. Features históricas con ventana expansiva estricta	§ 7 Validación
pct_rentabilidad relleno con 0 e imputación de costes por medias	Métrica eliminada del alcance. No se usa facturación ni costes en ninguna parte del proyecto	§ 1 Problema
IPs y nombres de base de datos en el repositorio	Todas las conexiones por .env, que no se versiona. Comprobación automática antes de cada commit (src/_check_seguridad.py). Además, las versiones anteriores de las Entregas 2 y 3 ya se corrigieron (host/BD reales sustituidos por marcadores genéricos) y el fix está subido a GitHub	§ 10.2 Seguridad
Trabajo mezclado con carpetas ajenas	Repositorio independiente creado (pfm-estimacion-duracion-procesos), con las cinco entregas y sin historial heredado. Pendiente solo conectarlo a un remoto de GitHub y purgar el historial del repositorio de curso, con los pasos exactos anotados	BLOQUEOS.md, B-003

1. Problema que se busca resolver

1.1 Qué ocurre hoy y por qué es un problema

En la asesoría, cada proceso (presentar un modelo tributario, cerrar una contabilidad) se ejecuta sin ninguna estimación previa de cuánto tiempo llevará, y al cerrar una campaña nadie revisa sistemáticamente qué negociaciones se han disparado en tiempo respecto a lo habitual. El trabajo atípico —una incidencia, un cliente más complejo de lo esperado, un registro de tiempo mal hecho— pasa desapercibido salvo que alguien tropiece con él.

1.2 Quién usa el resultado y para qué decisión

Un gestor o responsable de equipo, en dos momentos distintos:

Uso	Momento	Decisión que apoya
Planificación	Antes de ejecutar el proceso	Estimar la carga de trabajo de una campaña
Control	Al cerrar la campaña	Decidir qué negociaciones merece revisar, de entre miles

La detección de anomalías **no es un segundo modelo**: es el residuo del modelo de planificación. Si el modelo estima 24 min para un proceso y se han imputado 1.004, ese residuo es la señal. Entrenar un detector de anomalías aparte (p. ej. un Isolation Forest) sería redundante y contradice el alcance decidido tras el feedback recibido.

1.3 Qué resultado se considera útil

Dos condiciones, medidas y no supuestas: (a) que el modelo mejore de forma clara un cálculo de referencia muy simple (la mediana histórica por tipo de proceso), y (b) que el volumen de negociaciones señaladas como anómalas sea lo bastante pequeño como para que una persona pueda revisarlo de verdad (se fija el 5 % como límite de lo manejable). Ambas condiciones se miden en las secciones 6 y 7, y el resultado —incluso cuando la primera no se alcanza del todo— se reporta tal cual, no se ajusta a posteriori.

1.4 Alcance: una sola línea, un solo pipeline

Las versiones anteriores del proyecto abarcaban predicción de rentabilidad, detección de anomalías y segmentación de clientes a la vez, con la unidad de observación cliente × mes y una extrapolación a 2027 con solo 19 meses de histórico. Este planteamiento reduce el alcance a una sola línea (duración de procesos) y a un solo pipeline: **Modelos de impuestos**.

Por qué ese pipeline y no otro, con las cifras que lo sostienen:

Criterio	Cifra
Etiqueta nativa del proceso, sin heurística de texto	El campo <i>Modelo presentado</i> del CRM tiene 52 valores de lista; 16.941 de las 17.223 negociaciones del pipeline lo tienen relleno (98,4 %)
Repeticiones suficientes por clase	25 valores de proceso con 30 o más negociaciones cerradas con tiempo; el más frecuente tiene 3.943
Permite validación temporal real	6.821 negociaciones cerradas en 2025 y 6.192 en 2026, seis campañas trimestrales en la ventana

Contabilidad queda como extensión (mismo método, para comprobar que se transfiere) y Rentas queda fuera del MVP (solo dos campañas, no admite validación temporal). El código recibe el pipeline como parámetro (PIPELINE_OBJETIVO); extenderlo a otro pipeline no requiere tocar la lógica.

2. Análisis de datos planteado y utilidad esperada

Todo lo de esta sección se ejecutó **antes** de plantear ningún modelo, para no afirmar nada sobre los datos sin haberlo medido — es la corrección directa al feedback de “acceso garantizado” y “calidad excelente” sin explorar.

2.1 Preguntas que se responden con los datos

Pregunta	Análisis	Resultado
¿Cuánto del trabajo real llega a verse?	Cobertura: horas con y sin negociación asociada	11,71 % de las horas imputadas (4.066,6 h) no cuelga de ninguna negociación
¿El target es fiable o está distorsionado por el registro manual?	Sesgo de redondeo: reparto de imputaciones en múltiplos exactos de 60/30/15/5 min	93,91 % de valores no redondos — se registra con cronómetro, no en bloques
¿Qué forma tiene la variable objetivo?	Distribución de minutos_total: mediana, P90, P99, máximo	Cola muy larga: ratio P99/mediana = 30,8
¿Cuánto se pierde por censura?	Reparto por estado (ganada/perdida/en curso)	13,10 % pérdidas, 0,52 % en curso, quedan fuera del modelo
¿Se ven las campañas trimestrales?	Estacionalidad: negociaciones cerradas por trimestre natural, por proceso	Confirmado; permite el split temporal 2025□2026
¿Hay concentración de trabajo en pocas personas?	Negociaciones por empleado	34 empleados imputan en el pipeline; 8 con menos de 30 negociaciones
¿Cuántas negociaciones tienen más de un empleado?	% de negociaciones multi-empleado	3,84 % — relevante para decidir si el modelo de control necesita n_empleados
¿Hay incoherencias que haya que filtrar o declarar?	Negociaciones con 0 minutos, con más de 8 h, con imputaciones fuera de ventana	21,74 % del pipeline con 0 minutos (censura por selección, no se elimina, se declara)

2.2 Cómo alimenta el modelado y el MVP

- El sesgo de redondeo (93,91 % no redondo) descarta la hipótesis de que el techo del error viniera de la granularidad de registro — el ruido tiene otro origen, y eso justifica no perseguir un MAE arbitrariamente bajo.
- La cola larga (ratio 30,8) es la razón directa de modelar $\log_{10}(\text{minutos_total})$ y de evaluar con MAE/MedAE en vez de RMSE (secciones 6 y 7).
- La cobertura (11,71 % de horas huérfanas, 21,74 % de negociaciones a 0 minutos) se incorpora al MVP como limitación explícita, no se oculta ni se corrige artificialmente.
- Las figuras que se incorporan al informe final: histograma de $\log_{10}(\text{minutos_total})$, boxplot de minutos por proceso, serie temporal de negociaciones cerradas por mes y barras del sesgo de redondeo (output/figuras/01-04_*.png).

3. Tipo de modelos que se van a plantear

Tipo de tarea: regresión (estimar minutos, con $\log_{1p}$ como transformación del objetivo). La detección de anomalías se deriva del residuo de este mismo modelo de regresión — no es un tipo de tarea aparte.

Alternativa	Tipo	Por qué se plantea	Limitación principal
Baseline (B1)	Mediana por proceso, ajustada solo en train	Referencia mínima defendible: “este tipo de modelo tributario suele tardar X”. Si el modelo no la bate con margen, no se justifica usarlo	No captura nada específico del cliente ni de la campaña — solo el tipo de proceso
Modelo candidato 1 (M1)	Regresión lineal sobre $\log_{1p}$, codificación one-hot	Interpretable, referencia de qué aporta la linealidad frente a la mediana	No captura relaciones no lineales ni interacciones entre features
Modelo candidato 2 (M2)	HistGradientBoosting	Permite comprobar si una mayor complejidad mejora el resultado; gestiona NaN de forma nativa (relevante porque las features históricas tienen NaN por diseño anti-leakage)	Mayor riesgo de sobreajuste y menor interpretabilidad directa que M1; requiere importancia por permutación para explicarse
Variante (M3)	M2 con pérdida cuantílica ($q = 0,1 / 0,5 / 0,9$)	Da un rango en vez de un punto — “entre 25 y 70 min” es más honesto para planificar que un único número, y la anchura del intervalo es en sí misma información	Los cuantiles se calibran con train (2025) y pueden no transferirse a una campaña con cola distinta (2026)
Modelo de control	M2 + responsable_id_grp + n_empleados	Comprueba si el responsable aporta señal — se reporta aparte, nunca para evaluar personas	No es el modelo de planificación (usa una variable que no se conoce hasta después de asignar el trabajo); solo para detección de anomalías de proceso

No se plantean modelos de detección de anomalías independientes (Isolation Forest, autoencoders): el alcance acordado tras el feedback usa el residuo del propio modelo de regresión, no un segundo modelo.

4. Datos de entrada del análisis y los modelos

Dataset: output/dataset_modelo.parquet, generado por src/03_dataset.py a partir de la capa gold (Fase 3). **Granularidad:** una fila = una negociación del pipeline objetivo, cerrada, ganada y con tiempo imputado. **Clave:** deal_id. **Fecha de referencia:** fecha_creacion (es el instante en que, en la práctica, se necesitaría la predicción). **Filas finales:** 13.013, sobre 1.036 clientes distintos.

Entrada	Descripción	Granularidad / tipo	Uso en el modelo
proceso	Modelo tributario presentado (303, 111, 200...)	categoría	Feature directa — la de mayor peso junto con el historial de cliente
ejercicio	Año fiscal	numérica (21,18 % nulos)	Feature directa, importancia casi nula (0,0000)
trimestre_fiscal	Trimestre natural de (fecha_creacion - 1 mes), derivado	categoría	Feature directa; validada al 99,63 % contra el campo declarado del CRM donde este es comparable
mes_creacion	Mes de creación de la negociación (1-12)	categoría	Feature directa, importancia baja
dias_desde_alta_cliente	Antigüedad del cliente en días	numérica (0,11 % nulos)	Feature directa
n_procesos_previos_cliente	Nº de negociaciones previas de ese cliente, ventana expansiva	numérica histórica	Resume el volumen de relación previa con el cliente
mediana_min_cliente_historial	Mediana histórica de minutos de ese cliente, ventana expansiva	numérica histórica (17,23 % nulos)	La feature de mayor importancia por permutación (0,0869)
mediana_min_proceso_historial	Mediana histórica de minutos de ese proceso, ventana expansiva	numérica histórica (17,31 % nulos)	Resume el nivel típico del proceso, más allá de la etiqueta
n_deals_misma_campana	Nº de negociaciones de la misma campaña creadas hasta esa fecha	numérica	Proxy de carga de la campaña en curso
es_primera_vez_cliente	El cliente no tiene historial previo en ese proceso	binaria	Marca los casos sin historial, que reciben NaN en las features históricas

Variables que no se utilizan, y por qué: minutos_max_imputacion, n_imputaciones, n_tareas, n_empleados, fecha_ultima_imputacion, fecha_cierre, fecha_primera_imputacion, etapa, etapa_id, semantica, cerrada. Todas se conocen **solo después** de ejecutar el proceso — usarlas sería fuga de información directa. src/03_dataset.py comprueba su ausencia y aborta si alguna aparece. La única excepción es n_empleados, reservada al modelo de control (sección 3), que no es el modelo de planificación.

Qué información estaría realmente disponible en el momento de generar la predicción: exactamente las diez columnas de la tabla — nada que dependa de tareas, imputaciones o fechas de cierre de la propia negociación que se está prediciendo.

5. Datos de salida y forma de consumo

Campo de salida	Descripción	Tipo	Uso posterior
deal_id	Identificador de la negociación	integer	Trazabilidad; unión con el resto de tablas del proyecto
prediccion_min	Minutos estimados (expm1 de la predicción en log1p)	float	Planificación de carga antes de ejecutar el proceso
q10_min / q90_min	Intervalo de predicción (solo M3)	float	Rango de planificación; anchura mediana 14,5 min
residuo_min	minutos_reales - prediccion_min	float	Base del cálculo de anomalía
z	Residuo estandarizado por la sigma del proceso (out-of-fold)	float	Score de anomalía
tipo_anomalia	normal / exceso / defecto según $ z > 3$	categorica	Filtrado y priorización de casos a revisar

Formato: tabla parquet (output/predicciones_planificacion.parquet) más los informes en mark-down de cada fase (output/0X_*.md), pensados para integrarse después en un panel de revisión (ver Entrega 5).

Cómo lo usa el gestor: antes de ejecutar, prediccion_min (y el intervalo de M3) para dimensionar la carga de la campaña; al cerrarla, la lista de negociaciones con tipo_anomalia = exceso para priorizar cuáles revisar, con el residuo y el contexto descriptivo del caso (sección 7 de la memoria de resultados) como apoyo para juzgarlo.

Qué explicación se muestra: el multiplicador “veces lo esperado” (más legible que el z-score en bruto), la mediana histórica del proceso y del cliente como referencia, y el valor de las variables de ese caso concreto — nunca la predicción sola, sin contexto. No se muestran “los factores que explican ese caso”: la importancia por permutación usada en el proyecto (sección 6 de la memoria de resultados) es global, calculada sobre todo el test, y no permite atribuir causas a una negociación individual sin una técnica de explicación local que este proyecto no implementa.

6. Estrategia para diseñar y seleccionar el modelo

- Preparación del dataset:** filtros de inclusión aplicados en orden, documentando cuántas filas caen en cada uno (pipeline ☐ cerrada ☐ ganada ☐ minutos > 0 ☐ proceso no vacío), de 30.836 negociaciones de partida a 13.013 finales.
- Definición del target:** log1p(minutos_total); todas las métricas se deshacen a minutos con expm1 antes de reportarse — un MAE en escala logarítmica no significa nada para un gestor.
- Baseline:** los cuatro baselines de la sección 3 se calculan **antes** que cualquier modelo, ajustados solo con train. B1 (mediana por proceso) se fija como referencia: MAE = 16,37 min en el test temporal.
- Modelos candidatos:** M1 y M2 de la sección 3, más la variante M3 y el modelo de control, entrenados en ese orden.
- Preprocesamiento:** sin escalado (no lo necesita HistGradientBoostingRegressor); categorías no vistas en train se convierten a NaN en vez de asignarse a la más frecuente (decisión conservadora, no

inventa pertenencia); procesos con menos de 100 casos en train se agrupan en OTROS en una de las variantes del bucle de mejora.

6. **Criterios de comparación:** MAE en minutos sobre la validación interna (GroupKFold(4) por cliente dentro de train) como criterio de decisión; estabilidad (mejora sostenida en los 4 folds); interpretabilidad (importancia por permutación); coste computacional (no es un factor limitante con este volumen de datos).

7. **Regla de decisión final — bucle de mejora con criterio de parada declarado antes de abrirlo:**

Elemento	Valor
Métrica de decisión	MAE en minutos sobre GroupKFold(4) por cliente, dentro de train
Umbral de aceptación	Mejora $\geq 10\%$ sobre el MAE de B1 en esa misma validación (11,53 min)
Intentos máximos	5, en un orden fijado de antemano
Papel del test temporal	Ninguno en la decisión de parada — aparece en la tabla solo como trayectoria observada

Resultado real del bucle: se agotaron los 5 intentos (agrupar procesos poco frecuentes, features de carga de campaña, ajuste de hiperparámetros, target encoding por cliente dentro de cada fold, recorte de la cola al P99 solo en train) sin alcanzar el 10 %. La variante elegida (ajuste de hiperparámetros, intento 3) es la mejor en validación interna, **no** la mejor en test — eso confirma que la selección no miró el conjunto de evaluación para decidir (detalle completo en la Entrega de resultados, output/05_modelos.md).

La selección no se basó en la métrica más alta a secas: el intento 4 (target encoding) obtuvo peor MAE de validación que el intento 3 y se descartó por eso, no por su MAE de test.

7. Estrategia de validación y evaluación

Elemento	Decisión prevista	Justificación
Separación de datos	Split temporal (train: cerradas 2025, 6.821 filas · test: cerradas 2026, 6.192 filas) + GroupKFold(4) por cliente dentro de train	Reproduce el uso real (se entrena con el pasado, se aplica al futuro) y evita que el mismo cliente aparezca en ambos lados de la validación interna
Métrica principal	MAE en minutos, deshecho de log1p	Refleja el error tal como lo entendería un gestor; MedAE se reporta como complemento robusto a la cola
Baseline	B1 — mediana de train por tipo de proceso	Es el mínimo defendible: si el modelo no lo mejora con margen, no se justifica la complejidad añadida
Criterio de aceptación	Mejora $\geq 10\%$ sobre B1 en la validación interna, máximo 5 intentos	Fijado antes de entrenar nada, para no mover el listón según conviniera al resultado

Cómo se evita la fuga de información: toda feature histórica se calcula únicamente con negociaciones cuya fecha_cierre es estrictamente anterior a la fecha_creacion de la fila (ventana expansiva, nunca el

conjunto completo); las filas sin historial reciben NaN, no la media global. Verificación cuantitativa: ninguna feature supera 0,95 de asociación con el target dentro de train — la más alta es proceso, con 0,441.

Resultado frente al baseline (test temporal, todas las métricas en minutos):

Modelo	MAE	Mejora sobre B1	MedAE	% ±5 min	% ±15 min
B1 (referencia)	16,37	0,00 %	4,88	50,95	72,37
M1 regresión lineal	16,40	−0,18 %	5,91	44,62	74,63
M2 gradient boosting	15,50	5,31 %	4,65	52,05	80,17
M3 cuantil 0,5	15,37	6,11 %	4,42	53,42	80,02
Modelo de control	14,94	8,74 %	5,18	49,03	78,81

Estabilidad (GroupKFold(4) por cliente, dentro de train): M2 mejora a B1 en los 4 de 4 folds, con ganancias de entre el 1,66 % y el 2,77 %.

Análisis de errores y casos extremos: los dos mayores errores de test son negociaciones del mismo proceso (347), con 1.003,7 y 795,4 minutos reales frente a una mediana histórica de ese proceso de 22,8 min — ninguna feature disponible antes de ejecutar el proceso anticipa esa diferencia. Hay además deriva entre campañas: el P99 de minutos_total pasa de 143,7 min en train a 189,9 min en test.

Qué resultado mínimo se consideraría aceptable, y qué se hizo al no alcanzarlo: el umbral fijado (10 % de mejora) no se alcanzó (5,31 % real). Conforme a lo decidido antes de empezar, esto se documenta como resultado negativo — no se tocó el test, no se recortaron casos difíciles ni se reajustó el baseline a la baja. El proyecto continúa usando M2, porque aunque su ganancia de planificación es modesta, su residuo es la base útil de la sección de anomalías (ver Entrega de resultados, § 8).

8. Riesgos y alternativas

¿La variable objetivo está disponible y representa el fenómeno que se quiere predecir? Disponible sí; representa el fenómeno de forma parcial. Es tiempo *imputado*, no medido: el 93,91 % de los valores no son redondos (se cronometra, no se estima en bloques), pero el 21,74 % de las negociaciones cerradas del pipeline tiene 0 minutos y el 11,71 % de las horas imputadas no cuelga de ninguna negociación. El modelo aprende del trabajo que llegó a registrarse, no de todo el trabajo real.

¿Existe riesgo de leakage? Se mitigó con la regla de ventana expansiva estricta (sección 7) y se verificó cuantitativamente (máxima asociación 0,441, muy lejos del umbral de 0,95 fijado como alarma).

¿Volumen, histórico y calidad suficientes? Volumen sí (13.013 filas). Histórico limitado: la validación temporal se apoya en dos campañas (2025 y 2026); con solo dos años, la deriva medida entre ellas no puede separarse de la variación año a año normal.

¿Hay desbalanceo, cambios temporales o segmentos con pocos datos? Los tres a la vez: la distribución del target tiene una cola muy larga (ratio P99/mediana = 30,8); hay deriva temporal medible entre campañas (P99 pasa de 143,7 a 189,9 min); y varios procesos tienen menos de 20 casos en train, lo que obliga a usar la sigma global del pipeline en vez de la propia del proceso para el cálculo de anomalías.

¿Qué parte de la estrategia genera más incertidumbre? Los intervalos de M3: cubren el real en el 54,80 % de los casos de test frente al 80 % nominal — están mal calibrados por la misma deriva entre campañas, y no son utilizables como garantía de cobertura sin recalibrarlos por campaña.

¿Qué alternativa se aplicó al no superar el baseline con margen? No se abrió un sexto intento fuera de lo planeado, ni se tocó el test: se documentó la mejora real (5,31 %) como resultado por debajo del umbral, con las tres causas medidas que lo explican (cola larga, deriva temporal, censura del target — detalle en la Entrega de resultados). El modelo queda como **prototipo**: aporta una mejora real pero modesta,

todavía insuficiente para justificar que sustituya a la mediana histórica en producción. Se conserva porque su residuo es la base de la detección de anomalías, donde el proyecto reporta el valor más claro (3,86 % de tasa de marcado, dentro del límite de manejabilidad del 5 %) — con la misma cautela: el contraste ciego con un experto dio un 52,6 % de acuerdo (output/06_anomalias.md, § 5.1), un resultado modesto que tampoco basta todavía para tomar decisiones operativas sin revisión humana. El siguiente paso no es otro algoritmo, sino incorporar variables que expliquen la complejidad real de cada caso y volver a validar.

9. Limitaciones declaradas

1. **El target es tiempo imputado manualmente, no medido.** El modelo aprende tanto el esfuerzo real como el hábito de imputación. El registro es cronometrado —el 93,91 % de las imputaciones tiene un valor no redondo—, lo que descarta el redondeo en bloques como fuente principal de ruido, pero no garantiza que el cronómetro se arranque y se pare cuando empieza y acaba el trabajo.
2. **Solo se observan negociaciones cerradas y ganadas.** Las 2.257 pérdidas (13,10 %) y las 90 en curso (0,52 %) del pipeline quedan censuradas y fuera del modelo.
3. **El trabajo que no cuelga de ninguna negociación es invisible al modelo.** Son 4.066,6 h, el 11,71 % de las horas imputadas en la ventana. A esto se suma que el 21,74 % de las negociaciones cerradas del pipeline no tiene ningún minuto imputado.
4. **El histórico cubre un número limitado de campañas.** La validación temporal se apoya en los cierres de 2026 (6.192 negociaciones) frente a los de 2025 (6.821). Con dos años, la deriva medida entre campañas —el P99 pasa de 143,7 a 189,9 min— no puede separarse de la variación año a año.
5. **Los resultados son específicos de esta asesoría.** Dependen de su cartera de clientes, de su reparto de modelos tributarios y de sus hábitos de imputación. No hay base para extrapolarlos a otra asesoría.
6. **El modelo de control incluye al responsable como variable.** Su finalidad es detectar anomalías de proceso, no evaluar el desempeño de personas. Se reporta por separado del modelo de planificación, que no lo incluye, y su uso queda restringido a la revisión de casos.

10. Trabajo futuro y estado de la entrega

10.1 Qué desbloquearía cada línea

Línea	Qué falta para abordarla
Mejorar la detección de anomalías	No es otro algoritmo: incorporar variables que capturen la complejidad real del caso (ajustes, amortizaciones, deducciones, volumen intracomunitario — grupo 1 de la validación experta, output/06_anomalias.md § 5.1) y repetir la validación ciega con experto
Extensión a contabilidad	Ejecutar los mismos scripts cambiando PIPELINE_OBJETIVO. Volumen disponible: 10.347,6 h entre Contabilidad Interna, Contabilidad Externa y Cierres. No requiere código nuevo
Extensión a rentas	Requiere una tercera campaña. Con dos (2025 y 2026) la validación temporal se reduce a un único corte

Línea	Qué falta para abordarla
Recalibrar los intervalos de M3	Estimar los cuantiles por campaña en lugar de sobre train completo, y medir de nuevo la cobertura frente al 80 % nominal
Reducir la censura del 21,74 % de negociaciones sin tiempo	Es un cambio de proceso en la asesoría, no de modelo: imputar tiempo a toda negociación cerrada
Integrar el panel de revisión (Entrega 5)	Conectar la maqueta a los .parquet reales de esta entrega; hoy es solo visual

10.2 Seguridad y reproducibilidad

Las conexiones se configuran mediante un archivo .env que no se versiona. Antes de cada commit se ejecuta `src/_check_seguridad.py`, que busca en todo lo que se va a versionar patrones de dirección IP, cadenas de credencial y nombres de base de datos, y aborta si encuentra alguno. Los datos (*.csv, *.parquet, *.pkl) están excluidos del control de versiones; solo se versionan el código, los informes en markdown y las figuras.

Las versiones anteriores de las Entregas 2 y 3, que contenían un host y un nombre de base de datos reales, ya se corrigieron (sustituidos por marcadores genéricos) y el fix está publicado en el repositorio de curso. Las credenciales de acceso a la base de datos se han rotado.

Cada script de `src/` se ejecuta de cero sin pasos manuales:

```
py -m pip install -r requirements.txt
py src/00_descubrimiento.py
py src/01_extraccion.py
py src/02_eda.py
py src/03_dataset.py
py src/04_baselines.py
py src/05_modelos.py
py src/06_anomalias.py
```

10.3 Lo que queda pendiente

Pendiente	Estado
Conectar pfm-estimacion-duracion-procesos a un remoto de GitHub	El repositorio existe en local, completo (Entregas 1-5), sin historial heredado. Falta solo el push
Purgar del historial del repositorio de curso los commits antiguos con IP/BD	
Validación ciega con experto	Riesgo activo ya cerrado (versión visible corregida y credenciales rotadas); la purga de commits antiguos queda registrada en BLOQUEOS.md (B-003) sin urgencia Resuelta. Acuerdo del 52,6 % sobre 38 casos usables; detalle y las dos causas de desacuerdo medidas en <code>output/06_anomalias.md</code> , § 5.1

10.4 Trazabilidad de las cifras

Toda cifra de este documento procede de un script de `src/` y está en un informe de `output/`:

Sección	Script	Informe
1 Problema, 2 Análisis de datos	01_extraccion.py, 02_eda.py	RESUMEN_extraccion.md, 02_informe_calidad.md

Sección	Script	Informe
4 Datos de entrada	03_dataset.py	03_diccionario_datos.md
3, 6, 7 Modelos, estrategia y validación	04_baselines.py, 05_modelos.py	04_baselines.md, 05_modelos.md
5, 8 Datos de salida y riesgos (anomalías)	06_anomalias.py	06_anomalias.md

Las decisiones tomadas durante la ejecución, con su alternativa descartada, están en DECISIONES.md (D-001 a D-014). Los puntos en los que la realidad contradijo lo previsto, en BLOQUEOS.md (B-001 a B-006).